

**UNIVERSIDAD MAYOR DE SAN ANDRÉS
CARRERA DE INFORMÁTICA
FACULTAD DE CIENCIAS PURAS Y NATURALES**



MÉTODOS NUMÉRICOS

“Desafío Sistemas de Ecuaciones Lineales”

ESTUDIANTE:

ESQUIVEL CASTILLO VIVIAN ROXANA

LA PAZ -BOLIVIA
2026

INTRODUCCIÓN

El presente trabajo desarrolla un modelo matemático aplicado a un sistema médico-computacional basado en la resolución de sistemas de **ecuaciones lineales** de la forma **$Ax=b$** , con el objetivo de representar y analizar la interacción entre variables clínicas y decisiones terapéuticas asistidas por métodos numéricos.


El modelo se enfoca en la optimización de una terapia personalizada, donde cada variable representa un componente del tratamiento o del estado del paciente. En particular, se considera un sistema de cinco variables:

- x1: dosis de fármaco A (mg/día)
- x2: dosis de fármaco B (mg/día)
- x3: dosis de fármaco C (mg/día)
- x4: intensidad de terapia digital (sesiones o nivel de intervención)
- x5: ajuste terapéutico adaptativo basado en el sistema inteligente

Este último componente introduce el rol del sistema computacional como parte activa del proceso terapéutico, integrando retroalimentación algorítmica en la toma de decisiones.

Cada ecuación del sistema representa una **restricción clínica** distinta, asociada a condiciones fisiológicas del paciente, tales como respuesta metabólica, efecto terapéutico combinado, límites de toxicidad, carga fisiológica del tratamiento y ajuste dinámico del sistema inteligente.

El estudio se desarrolla bajo tres escenarios diferenciados: **caso ideal**, **caso bajo estrés clínico** y **caso mal condicionado**. Esta clasificación permite analizar cómo la variación en los parámetros del sistema afecta directamente la estabilidad numérica de la solución y, por ende, la confiabilidad del modelo en contextos clínicos.



PLANTEAMIENTO DEL PROBLEMA

En los sistemas modernos de apoyo a la decisión clínica, la determinación de tratamientos personalizados requiere analizar simultáneamente múltiples variables fisiológicas del paciente. **Factores como la edad, el peso corporal, el nivel de severidad de una enfermedad y el grado de actividad física** influyen directamente en la **respuesta terapéutica y en la dosificación óptima de los tratamientos**.

El presente trabajo propone un modelo matemático basado en sistemas de ecuaciones lineales para representar la interacción entre diferentes componentes terapéuticos y variables fisiológicas. El objetivo es **determinar una combinación adecuada de tratamientos que satisfaga las necesidades clínicas del paciente bajo diferentes condiciones operativas**.

El **sistema desarrollado se analiza bajo tres escenarios distintos**: un escenario ideal donde las variables presentan un comportamiento estable, un escenario de estrés donde la demanda fisiológica aumenta significativamente y un escenario mal condicionado donde existe alta dependencia entre variables, generando dificultades numéricas en la resolución.

La formulación matemática permite evaluar no solamente la solución del sistema, sino también el **comportamiento y la eficiencia de distintos métodos numéricos** frente a cambios en el condicionamiento de la matriz de coeficientes.

DEFINICIÓN DE VARIABLES Y MODELADO MATEMÁTICO

El modelo desarrollado representa un sistema clínico-computacional orientado a la optimización de tratamientos personalizados. La interacción entre diferentes componentes terapéuticos y características fisiológicas del paciente se modela mediante un sistema de ecuaciones lineales de la forma:

$$Ax = b$$

donde A representa la matriz de coeficientes, x el vector de variables desconocidas y b el vector de requerimientos clínicos.

VARIABLES DEL SISTEMA

Las variables desconocidas del modelo representan componentes terapéuticos cuya combinación debe satisfacer las necesidades fisiológicas del paciente.

Variable	Interpretación
x_1	Dosis diaria del componente terapéutico asociado al soporte proteico
x_2	Dosis diaria del componente terapéutico asociado al soporte lipídico
x_3	Dosis diaria del componente terapéutico asociado al soporte energético
x_4	Intensidad de terapia digital aplicada al paciente
x_5	Ajuste terapéutico adaptativo generado por el sistema inteligente

Cada variable se expresa en unidades de dosificación equivalentes por día y constituye una incógnita que debe ser determinada mediante los métodos numéricos implementados.

VARIABLES CLÍNICAS DE ENTRADA

La construcción del sistema depende de parámetros fisiológicos obtenidos del paciente.

Parámetro	Descripción
Edad	Edad del paciente en años
Peso	Peso corporal en kilogramos
Severidad	Nivel de gravedad clínica en escala de 0 a 10
Actividad	Nivel de actividad física en escala de 0 a 10

Estas variables modifican directamente los coeficientes de la matriz A y los valores del vector b, permitiendo adaptar el sistema a diferentes condiciones clínicas.

INTERPRETACIÓN DEL VECTOR B

El vector b representa las demandas fisiológicas que deben satisfacerse mediante la combinación adecuada de tratamientos. Cada componente de **b** expresa una necesidad clínica específica relacionada con requerimientos metabólicos, demanda energética, intensidad terapéutica y capacidad adaptativa del paciente.

De esta manera, resolver el sistema **Ax=b** permite determinar los valores de las variables terapéuticas necesarios para satisfacer simultáneamente todas las restricciones clínicas consideradas por el modelo.

CONSTRUCCIÓN DEL SISTEMA MATRICIAL

El sistema de ecuaciones lineales **Ax=b** se construye a partir de un modelo clínico-computacional en el cual las características fisiológicas del paciente influyen directamente sobre los coeficientes de la matriz de interacción y sobre los requerimientos clínicos representados por el vector **b**. Debido a que las variables de entrada poseen diferentes unidades de medida y órdenes de magnitud, se aplica previamente un proceso de normalización. Esta transformación permite expresar todas las variables en una escala comparable, evitando que alguna de ellas domine numéricamente la construcción del sistema.

Las variables normalizadas se definen mediante las siguientes expresiones:

$$edad_n = \frac{edad}{50}$$

$$peso_n = \frac{peso}{70}$$

$$severidad_n = \frac{severidad}{10}$$

$$actividad_n = \frac{actividad}{10}$$

donde:

- edad corresponde a la edad del paciente expresada en años.
- peso representa el peso corporal en kilogramos.
- severidad indica el nivel de gravedad clínica en una escala de 0 a 10.
- actividad representa el nivel de actividad física del paciente en una escala de 0 a 10.

Los denominadores utilizados corresponden a valores de referencia seleccionados para transformar las variables originales en magnitudes adimensionales cercanas al intervalo [0,2]. Esta estrategia mejora la estabilidad numérica del modelo y facilita la interpretación de la influencia relativa de cada factor clínico.

La normalización proporciona tres ventajas fundamentales:

- Homogeneiza variables expresadas en distintas unidades de medida.
- Reduce el riesgo de desequilibrios numéricos durante la resolución del sistema.
- Favorece la convergencia de los métodos iterativos implementados.

Una vez obtenidas las variables normalizadas, estas son incorporadas en la matriz de coeficientes y en el vector de términos independientes, permitiendo construir un sistema lineal adaptado a las características particulares de cada paciente.

JUSTIFICACIÓN DE CADA FACTOR

1. EDAD / 50

$$edad_n = \frac{edad}{50}$$

El valor 50 se adopta como referencia debido a que representa aproximadamente una edad adulta intermedia. Esta elección permite que edades comprendidas entre 0 y 100 años sean transformadas a valores cercanos al intervalo [0,2], evitando magnitudes excesivamente grandes dentro del sistema.

3. SEVERIDAD / 10

$$severidad_n = \frac{severidad}{10}$$

La severidad se mide mediante una escala discreta de 0 a 10, donde 0 representa ausencia de afectación y 10 corresponde al máximo nivel de gravedad considerado por el modelo. La división entre 10 transforma directamente la variable a un rango normalizado entre 0 y 1.

2. PESO / 70

$$peso_n = \frac{peso}{70}$$

El valor 70 kg se utiliza como referencia por corresponder a un peso promedio frecuentemente empleado en estudios biomédicos y farmacológicos. La normalización respecto a este valor permite representar la condición corporal del paciente mediante una magnitud relativa fácilmente interpretable.

4. ACTIVIDAD / 10

$$actividad_n = \frac{actividad}{10}$$

El nivel de actividad física también se representa mediante una escala de 0 a 10. Su normalización permite incorporar este factor al modelo utilizando una magnitud comparable con las demás variables clínicas.



FUNDAMENTACIÓN MATEMÁTICA

Desde el punto de vista numérico, la normalización puede interpretarse como una transformación lineal de escala:

$$x_n = \frac{x}{x_{ref}}$$

donde xref representa un valor de referencia para cada variable clínica. Esta transformación conserva las relaciones proporcionales existentes entre los datos originales y contribuye a generar matrices mejor condicionadas, favoreciendo el desempeño de métodos como Jacobi, Gauss-Seidel, SOR y Gradiente Conjugado Precondicionado.

CONSTRUCCIÓN DE LA MATRIZ A

La matriz de coeficientes A representa las interacciones existentes entre los distintos componentes terapéuticos considerados en el modelo. Cada elemento de la matriz cuantifica la influencia que una variable ejerce sobre otra dentro del sistema clínico-computacional.

Una vez normalizadas las variables fisiológicas del paciente, la matriz se construye mediante la siguiente expresión:

$$A = \begin{bmatrix} 32 + 4E & 1.5 & 0.8 & 0.5 & 0.2 \\ 1.5 & 28 + 3P & 2.0 & 0.6 & 0.3 \\ 0.8 & 2.0 & 25 + 5A & 1.0 & 0.4 \\ 0.5 & 0.6 & 1.0 & 22 + 2S & 0.7 \\ 0.2 & 0.3 & 0.4 & 0.7 & 18 \end{bmatrix}$$

donde:

E=edad

P=peso

S=severidad

A=actividad

Los elementos de la diagonal principal representan la influencia predominante de cada variable sobre sí misma, mientras que los elementos fuera de la diagonal modelan las interacciones cruzadas entre los distintos componentes del sistema.

JUSTIFICACIÓN DE LA DIAGONAL PRINCIPAL

Los coeficientes ubicados en la diagonal principal poseen magnitudes considerablemente mayores que los coeficientes externos.

32+4E

28+3P

25+5A

22+2S

18

Esta elección responde a la necesidad de representar que cada componente terapéutico tiene una influencia directa significativamente mayor que las interacciones secundarias generadas por otros componentes.

Desde el punto de vista numérico, una diagonal dominante mejora la estabilidad del sistema y favorece la convergencia de los métodos iterativos implementados.

JUSTIFICACIÓN DE LAS INTERACCIONES CRUZADAS

Los elementos fuera de la diagonal principal representan dependencias e influencias mutuas entre las variables del modelo.
Por ejemplo:

$$a_{12}=a_{21}=1.5$$

representa la interacción entre los dos primeros componentes terapéuticos.

De forma similar:

$$a_{23}=a_{32}=2.0$$

representa una interacción más significativa entre las variables asociadas al soporte lipídico y energético.
Los demás coeficientes se mantienen deliberadamente pequeños para evitar que las relaciones cruzadas dominen el comportamiento global del sistema.

Esta estrategia permite conservar un equilibrio entre realismo clínico y estabilidad matemática.

PROPIEDAD DE SIMETRÍA

Una característica fundamental de la matriz construida es su simetría.

$$A=A^T$$

La simetría implica que la influencia de una variable sobre otra es recíproca dentro del modelo. Matemáticamente, esto significa que:

$$a_{ij}=a_{ji}$$

para todo par de índices i y j.

Esta propiedad resulta especialmente importante porque constituye una condición necesaria para la aplicación del método de Gradiente Conjugado Precondicionado.

PROPIEDAD DE DOMINANCIA DIAGONAL

Para cada fila de la matriz se verifica que el elemento diagonal es mayor que la suma de los valores absolutos de los elementos restantes de la misma fila.
Por ejemplo, para la primera fila:

$$32+4E>1.5+0.8+0.5+0.2$$
$$32+4E>3.0$$

lo cual se cumple para cualquier valor admisible de E.

De forma análoga, las demás filas satisfacen la misma condición.

La dominancia diagonal reduce la sensibilidad frente a perturbaciones numéricas y favorece la convergencia de los métodos iterativos utilizados en el estudio.



RELACIÓN CON EL GRADIENTE CONJUGADO PRECONDICIONADO

La matriz fue diseñada para aproximar una estructura simétrica definida positiva (SPD), condición requerida para garantizar la convergencia del método de Gradiente Conjugado Precondicionado.
La combinación de:

- Simetría
- Predominio diagonal
- Coeficientes positivos

Produce una matriz numéricamente estable y adecuada para evaluar el comportamiento comparativo de los métodos directos e iterativos considerados en el presente trabajo.

DEPENDENCIA PARAMÉTRICA DE LA MATRIZ

A diferencia de los sistemas lineales tradicionales donde los coeficientes permanecen constantes, la matriz propuesta se adapta dinámicamente a las características fisiológicas del paciente. Los elementos diagonales incorporan variables clínicas normalizadas que modifican la estructura del sistema en función de la condición particular analizada.

Por ejemplo, un incremento en la edad del paciente produce un aumento del coeficiente:

$$a_{11}=32+4E$$

mientras que un incremento en la actividad física modifica:

$$a_{33}=25+5A$$

Esta dependencia paramétrica permite representar diferentes perfiles clínicos sin alterar la estructura matemática general del modelo. Como resultado, cada paciente genera una matriz particular AAA, manteniendo las propiedades numéricas necesarias para la aplicación de los métodos estudiados.

ESTABILIDAD NUMÉRICA DE LA MATRIZ

La matriz fue diseñada con el objetivo de preservar la estabilidad numérica durante la resolución del sistema. La combinación de:


- Coeficientes positivos
- Simetría
- Predominancia diagonal
- Escalamiento previo de variables

Reduce la probabilidad de comportamientos inestables asociados a matrices cercanas a la singularidad.

Estas características permiten que métodos directos como la Factorización LU y métodos iterativos como Jacobi, Gauss-Seidel, SOR y Gradiente Conjugado Precondicionado puedan aplicarse bajo condiciones favorables de convergencia.

Además, la estructura propuesta facilita la generación controlada de escenarios experimentales con distintos niveles de condicionamiento, permitiendo estudiar el comportamiento de cada algoritmo frente a sistemas bien condicionados y mal condicionados.

CAPTURA DE LA MATRIZ A DENTRO DEL CÓDIGO



CONSTRUCCIÓN DEL VECTOR B

El vector bbb representa las demandas clínicas que deben ser satisfechas por el sistema terapéutico. Cada uno de sus componentes cuantifica un requerimiento fisiológico asociado a las características particulares del paciente.

Su construcción se define mediante:

$$b = \begin{bmatrix} 250 + 30S \\ 180 + 20P \\ 150 + 40A \\ 100 + 50S \\ 60 + 10E \end{bmatrix}$$

donde E, P, S y A corresponden a las variables clínicas normalizadas de edad, peso, severidad y actividad física.

Los términos constantes representan requerimientos base del modelo, mientras que los términos variables permiten ajustar dinámicamente las demandas clínicas en función de la condición específica del paciente. De esta manera, el vector b se adapta automáticamente a diferentes escenarios sin modificar la estructura general del sistema.

CONSTRUCCIÓN DE ESCENARIOS EXPERIMENTALES

Con el propósito de evaluar el desempeño y la estabilidad de los métodos numéricos implementados, se definieron tres escenarios experimentales que modifican las características de la matriz A y del vector b.

Con los datos:

$Edad = 50$

$Peso = 70$

$Severidad = 5$

$Actividad = 5$

Las variables normalizadas son:

$E = \frac{50}{50} = 1$

$P = \frac{70}{70} = 1$

$S = \frac{5}{10} = 0.5$

$A = \frac{5}{10} = 0.5$

ESCENARIO IDEAL

Corresponde al sistema base generado a partir de las variables clínicas normalizadas. En este caso la matriz conserva sus propiedades de simetría, predominancia diagonal y buen condicionamiento numérico, favoreciendo la convergencia de todos los métodos estudiados.

$A = \begin{bmatrix} 36 & 1.5 & 0.8 & 0.5 & 0.2 \\ 1.5 & 31 & 2 & 0.6 & 0.3 \\ 0.8 & 2 & 27.5 & 1 & 0.4 \\ 0.5 & 0.6 & 1 & 23 & 0.7 \\ 0.2 & 0.3 & 0.4 & 0.7 & 18 \end{bmatrix}$

$b = \begin{bmatrix} 265 \\ 200 \\ 170 \\ 125 \\ 70 \end{bmatrix}$

Por tanto, el sistema de ecuaciones es:


$36x_1 + 1.5x_2 + 0.8x_3 + 0.5x_4 + 0.2x_5 = 265$

$1.5x_1 + 31x_2 + 2x_3 + 0.6x_4 + 0.3x_5 = 200$

$0.8x_1 + 2x_2 + 27.5x_3 + x_4 + 0.4x_5 = 170$

$0.5x_1 + 0.6x_2 + x_3 + 23x_4 + 0.7x_5 = 125$

$0.2x_1 + 0.3x_2 + 0.4x_3 + 0.7x_4 + 18x_5 = 70$




ESCENARIO DE ESTRÉS

Se incrementan las demandas clínicas y las interacciones entre variables mediante modificaciones controladas en la matriz A y el vector b. Este escenario simula condiciones de mayor complejidad y permite analizar el comportamiento de los algoritmos frente a sistemas más exigentes.

$A = \begin{bmatrix} 27 & 5.7 & 3.04 & 1.9 & 0.76 \\ 5.7 & 23.25 & 7.6 & 2.28 & 1.14 \\ 3.04 & 7.6 & 20.625 & 3.8 & 1.52 \\ 1.9 & 2.28 & 3.8 & 17.25 & 2.66 \\ 0.76 & 1.14 & 1.52 & 2.66 & 13.5 \end{bmatrix}$

$b = \begin{bmatrix} 742 \\ 560 \\ 476 \\ 350 \\ 196 \end{bmatrix}$




ESCENARIO MAL CONDICIONADO

Se introduce una fuerte dependencia lineal entre filas de la matriz, generando un sistema cercano a la singularidad. Como consecuencia, el número de condición aumenta significativamente, permitiendo estudiar la sensibilidad numérica y la capacidad de convergencia de los distintos métodos frente a problemas mal condicionados.

$$A = \begin{bmatrix} 36 & 1.5 & 0.8 & 0.5 & 0.2 \\ 35.9856 & 1.5008 & 0.79968 & 0.4998 & 0.19992 \\ 0.8 & 2 & 27.5 & 1 & 0.4 \\ 0.5 & 0.6 & 1 & 23 & 0.7 \\ 0.2 & 0.3 & 0.4 & 0.7 & 18 \end{bmatrix}$$

$$b = \begin{bmatrix} 265 \\ 264.894 \\ 170 \\ 125 \\ 70 \end{bmatrix}$$



VALIDACIÓN MATEMÁTICA DEL SISTEMA

Antes de aplicar los métodos numéricos implementados, es necesario verificar que la matriz de coeficientes posea propiedades matemáticas que favorezcan la estabilidad del sistema y la convergencia de los algoritmos utilizados.

VERIFICACIÓN DE SIMETRÍA

La matriz de coeficientes fue diseñada de forma simétrica, cumpliendo la condición:

$$A = A^T$$

Esto implica que para todo par de elementos se verifica:

$$a_{ij} = a_{ji}$$

Por ejemplo:

$$a_{12} = a_{21} = 1.5$$

$$a_{13} = a_{31} = 0.8$$

$$a_{23} = a_{32} = 2.0$$

La propiedad de simetría permite representar relaciones recíprocas entre las variables del modelo y constituye un requisito fundamental para la aplicación del método de Gradiente Conjugado Precondicionado.

NÚMERO DE CONDICIÓN

El número de condición constituye un indicador de la sensibilidad de un sistema lineal frente a pequeñas perturbaciones en sus coeficientes o en los términos independientes.

Matemáticamente se define como:

$$\text{Cond}(A) = \|A\| \cdot \|A^{-1}\|$$

Valores reducidos indican sistemas estables y bien condicionados, mientras que valores elevados reflejan una mayor sensibilidad numérica y posibles dificultades durante la resolución.

Por esta razón, la aplicación calcula automáticamente el número de condición para clasificar cada escenario como ideal, bajo estrés o mal condicionado.

VERIFICACIÓN DE DOMINANCIA DIAGONAL

La matriz presenta predominancia diagonal debido a que los elementos de la diagonal principal poseen magnitudes considerablemente mayores que los coeficientes externos.

Para la primera fila del caso de estudio:

$$36 > 1.5 + 0.8 + 0.5 + 0.2$$

$$36 > 3$$

De forma análoga, las restantes filas cumplen la misma condición.

La predominancia diagonal contribuye a la estabilidad numérica del sistema y favorece la convergencia de métodos iterativos como Jacobi, Gauss-Seidel y SOR.

JUSTIFICACIÓN DEL GRADIENTE CONJUGADO PRECONDICIONADO

El método de Gradiente Conjugado Precondicionado requiere matrices simétricas y definidas positivas para garantizar convergencia.

La estructura de la matriz propuesta, caracterizada por su simetría, predominancia diagonal y coeficientes positivos, permite aproximar estas condiciones y favorece la aplicación del algoritmo.

Además, se emplea un preconditionador diagonal construido a partir de la diagonal principal de la matriz, con el objetivo de mejorar el comportamiento numérico y acelerar el proceso iterativo de convergencia.

MÉTODOS NUMÉRICOS IMPLEMENTADOS

Con el objetivo de resolver el sistema lineal generado por el modelo clínico-computacional, se implementaron métodos directos e iterativos que permiten comparar precisión, velocidad de convergencia y estabilidad numérica bajo distintos escenarios experimentales.

FACTORIZACIÓN LU CON PIVOTEO PARCIAL

La Factorización LU es un método directo que descompone la matriz de coeficientes en el producto de una matriz triangular inferior y una matriz triangular superior.

$$PA = LU$$

donde P representa la matriz de permutación asociada al pivoteo parcial.

La solución del sistema se obtiene mediante dos etapas:

$$Ly = Pb$$

$$Ux = y$$

El pivoteo parcial mejora la estabilidad numérica al evitar divisiones por valores muy pequeños y reducir errores de redondeo. Debido a su robustez, este método se utilizó como referencia principal para validar las soluciones obtenidas por los métodos iterativos.

MÉTODO SOR (SUCCESSIVE OVER-RELAXATION)

El método SOR introduce un factor de relajación ω con el propósito de acelerar la convergencia del método de Gauss-Seidel.

$$x_i^{(k+1)} = (1-\omega)x_i^{(k)} + \omega x^{Gs}$$

En la implementación desarrollada se utilizó:

$$\omega = 1.3$$

La elección de este valor permitió incrementar la velocidad de convergencia sin comprometer la estabilidad del algoritmo en los escenarios evaluados.

MÉTODO DE GAUSS-SEIDEL

Gauss-Seidel constituye una mejora del método de Jacobi, ya que utiliza inmediatamente los valores actualizados durante la misma iteración.

$$x_i^{(k+1)} = (b_i - \sum_{j \neq i} a_{ij}x_j) / a_{ii}$$

Esta característica suele producir una convergencia más rápida en comparación con Jacobi. Debido a la predominancia diagonal de la matriz utilizada, se espera un comportamiento estable y eficiente en la mayoría de los escenarios analizados.



MÉTODO DE JACOBI

El método de Jacobi es un algoritmo iterativo que calcula una nueva aproximación utilizando únicamente los valores obtenidos en la iteración anterior.

$$x_i^{(k+1)} = (b_i - \sum_{j \neq i} a_{ij}x_j^{(k)}) / a_{ii}$$

La convergencia del método depende principalmente de la estructura de la matriz, siendo especialmente favorable cuando existe predominancia diagonal. Su implementación permitió evaluar el comportamiento básico de los métodos iterativos frente a los distintos escenarios propuestos.

GRADIENTE CONJUGADO PRECONDICIONADO

El método de Gradiente Conjugado Precondicionado es un algoritmo iterativo diseñado para resolver sistemas lineales de gran eficiencia cuando la matriz es simétrica y definida positiva.

El procedimiento inicia calculando el residuo:


$$r_0 = b - Ax_0$$

Posteriormente se emplea un preconditionador diagonal construido a partir de la diagonal principal de la matriz:

$$M^{-1} = \text{diag}(A)^{-1}$$

El uso del preconditionador reduce los efectos del mal condicionamiento y mejora la velocidad de convergencia del método.

Debido a las propiedades estructurales de la matriz propuesta, este algoritmo constituye una alternativa eficiente para analizar el comportamiento del sistema bajo distintos niveles de complejidad numérica.



IMPLEMENTACIÓN Y RESOLUCIÓN DEL SISTEMA

La aplicación desarrollada genera automáticamente la matriz de coeficientes y el vector de términos independientes a partir de los parámetros fisiológicos ingresados por el usuario. Una vez construido el sistema lineal, se ejecutan los métodos numéricos implementados y se presentan los resultados obtenidos para su análisis comparativo.

CASO DE ESTUDIO

Para validar el funcionamiento de la aplicación se utilizó el conjunto de datos predeterminado:

Edad = 50 años
Peso = 70 kg
Severidad = 5
Actividad física = 5

Después del proceso de normalización se obtienen:

E = 1
P = 1
S = 0.5
A = 0.5

Sustituyendo estos valores en el modelo se genera el siguiente sistema lineal:

$36x_1 + 1.5x_2 + 0.8x_3 + 0.5x_4 + 0.2x_5 = 265$
 $1.5x_1 + 31x_2 + 2x_3 + 0.6x_4 + 0.3x_5 = 200$
 $0.8x_1 + 2x_2 + 27.5x_3 + x_4 + 0.4x_5 = 170$
 $0.5x_1 + 0.6x_2 + x_3 + 23x_4 + 0.7x_5 = 125$
 $0.2x_1 + 0.3x_2 + 0.4x_3 + 0.7x_4 + 18x_5 = 70$


OBTENCIÓN DE LA SOLUCIÓN

Una vez completadas las etapas de sustitución progresiva y regresiva, se obtiene el vector solución:

$x = [$
 x_1
 x_2
 x_3
 x_4
 $x_5]$

donde cada componente representa la cantidad óptima asociada a las variables terapéuticas definidas en el modelo.

Estos valores constituyen la referencia utilizada posteriormente para comparar la precisión y velocidad de convergencia de los métodos iterativos implementados.



RESOLUCIÓN MEDIANTE FACTORIZACIÓN LU

La solución principal del sistema se obtiene utilizando Factorización LU con pivoteo parcial.

El procedimiento consiste en descomponer la matriz original en:

$$PA = LU$$

Posteriormente se resuelve el sistema triangular inferior:

$$Ly = Pb$$

y finalmente el sistema triangular superior:

$$Ux = y$$

La implementación desarrollada genera automáticamente las matrices L y U, el vector intermedio y y la solución final x.

Debido a que la matriz utilizada presenta una estructura estable y diagonalmente dominante, el algoritmo no requiere intercambios significativos de filas y produce una solución numéricamente confiable.



RESULTADOS EXPERIMENTALES

Con el propósito de evaluar el comportamiento de los métodos numéricos implementados, se realizaron pruebas sobre los tres escenarios definidos durante el modelado del sistema: escenario ideal, escenario de estrés y escenario mal condicionado. Para cada caso se registró la solución obtenida mediante Factorización LU y el número de iteraciones requeridas por los métodos iterativos para alcanzar el criterio de convergencia establecido.

RESULTADOS DEL ESCENARIO IDEAL

La matriz conserva sus propiedades de estabilidad, simetría y predominancia diagonal, permitiendo que todos los algoritmos converjan satisfactoriamente.

SOLUCIÓN OBTENIDA MEDIANTE FACTORIZACIÓN LU

Variable	Resultado (mg/día)
x_1	6.9214
x_2	5.6459
x_3	5.3456
x_4	4.8008
x_5	3.4124

COMPARACIÓN DE MÉTODOS

Método	Iteraciones	Convergencia
Jacobi	9	Sí
Gauss-Seidel	6	Sí
SOR	16	Sí
Gradiente Conjugado Precondicionado	5	Sí
Factorización LU	1	Sí

Los resultados muestran que todos los algoritmos convergen correctamente. El método de Gradiente Conjugado Precondicionado presentó la convergencia más rápida entre los métodos iterativos, mientras que la Factorización LU obtuvo la solución exacta en una única ejecución.

RESULTADOS DEL ESCENARIO DE ESTRÉS

En este escenario se incrementan las demandas clínicas y las interacciones entre variables, generando un sistema de mayor complejidad numérica.

SOLUCIÓN OBTENIDA MEDIANTE FACTORIZACIÓN LU

Variable	Resultado (mg/día)
x_1	22.2679
x_2	13.0596
x_3	12.1277
x_4	12.1435
x_5	8.4039

COMPARACIÓN DE MÉTODOS

Método	Iteraciones	Convergencia
Jacobi	38	Sí
Gauss-Seidel	10	Sí
SOR	18	Sí
Gradiente Conjugado Precondicionado	5	Sí
Factorización LU	1	Sí

Se observa un incremento significativo en el número de iteraciones requeridas por Jacobi, pasando de 9 a 38 iteraciones. Sin embargo, todos los métodos lograron converger. El Gradiente Conjugado Precondicionado mantuvo un comportamiento estable, conservando la menor cantidad de iteraciones entre los métodos iterativos evaluados.

RESULTADOS DEL ESCENARIO MAL CONDICIONADO

Este escenario fue diseñado para generar una fuerte dependencia lineal entre filas de la matriz, aumentando considerablemente la sensibilidad numérica del sistema.

SOLUCIÓN OBTENIDA MEDIANTE FACTORIZACIÓN LU

Variable	Resultado (mg/día)
x_1	-35.0856
x_2	1054.1503
x_3	-21.986
x_4	-60.3268
x_5	-26.952

COMPARACIÓN DE MÉTODOS

Método	Iteraciones	Convergencia
Jacobi	250	No
Gauss-Seidel	5	Sí
SOR	250	No
Gradiente Conjugado Precondicionado	250	No
Factorización LU	1	Sí

Los resultados evidencian el impacto del mal condicionamiento sobre los algoritmos iterativos. Jacobi, SOR y Gradiente Conjugado Precondicionado alcanzaron el límite máximo de iteraciones sin lograr converger. Por el contrario, Gauss-Seidel mantuvo convergencia y la Factorización LU continuó proporcionando una solución válida debido a la naturaleza directa del método.

COMPARACIÓN GENERAL DE DESEMPEÑO

El comportamiento observado permite identificar diferencias importantes entre los métodos implementados.

- La Factorización LU fue el método más robusto, obteniendo solución en todos los escenarios.
- El Gradiente Conjugado Precondicionado presentó el mejor desempeño iterativo en los escenarios ideal y de estrés.
- Gauss-Seidel mostró el comportamiento más estable entre los métodos iterativos al converger incluso en el escenario mal condicionado.
- Jacobi fue el método más sensible al deterioro del condicionamiento de la matriz.
- El escenario mal condicionado evidenció la importancia del número de condición como indicador de estabilidad numérica.

Los resultados obtenidos confirman que la estructura de la matriz influye directamente sobre la velocidad de convergencia y la estabilidad de los algoritmos numéricos empleados.

ANÁLISIS DE RESULTADOS

Los resultados obtenidos evidencian que el comportamiento de los métodos numéricos depende directamente de las propiedades matemáticas de la matriz de coeficientes y del nivel de condicionamiento presente en cada escenario evaluado.

INFLUENCIA DEL CONDICIONAMIENTO DE LA MATRIZ

En el escenario ideal, la matriz presenta una estructura estable caracterizada por simetría, predominancia diagonal y baja sensibilidad numérica. Estas propiedades favorecen la convergencia de todos los métodos implementados, permitiendo obtener soluciones consistentes con un reducido número de iteraciones.

Al incrementar las interacciones entre variables en el escenario de estrés, el sistema mantiene convergencia, aunque algunos algoritmos requieren un mayor esfuerzo computacional. Este comportamiento demuestra que, a medida que aumenta la complejidad del sistema, la velocidad de convergencia comienza a verse afectada.

Por otra parte, el escenario mal condicionado genera una fuerte dependencia lineal entre filas de la matriz, incrementando significativamente la sensibilidad numérica del sistema. Como consecuencia, algunos métodos iterativos no logran satisfacer el criterio de convergencia dentro del límite establecido de iteraciones.

COMPARACIÓN ENTRE MÉTODOS DIRECTOS E ITERATIVOS

La Factorización LU fue el método más robusto durante todo el proceso experimental. Al tratarse de un método directo, su solución no depende de aproximaciones sucesivas, permitiendo obtener resultados incluso cuando el sistema presenta condiciones desfavorables.

Los métodos iterativos mostraron un comportamiento diferente debido a su dependencia de las propiedades estructurales de la matriz. En sistemas bien condicionados lograron converger rápidamente; sin embargo, su rendimiento disminuyó conforme aumentó la complejidad numérica del problema.

Esta diferencia confirma que los métodos directos ofrecen mayor estabilidad general, mientras que los métodos iterativos presentan ventajas principalmente en términos de eficiencia cuando las condiciones del sistema son favorables.

DESEMPEÑO DE LOS MÉTODOS ITERATIVOS

El método de Gradiente Conjugado Precondicionado presentó el mejor desempeño en los escenarios ideal y de estrés, alcanzando la convergencia con la menor cantidad de iteraciones. Este comportamiento confirma la efectividad del precondicionamiento diagonal aplicado sobre la matriz del sistema.

Gauss-Seidel demostró un comportamiento particularmente estable, logrando converger incluso en el escenario mal condicionado. Esto sugiere que la utilización inmediata de los valores actualizados durante cada iteración proporciona una ventaja significativa frente a otros métodos iterativos.

Por su parte, Jacobi presentó la mayor sensibilidad al deterioro del condicionamiento de la matriz. El incremento de iteraciones observado en el escenario de estrés y la falta de convergencia en el escenario mal condicionado reflejan las limitaciones de este algoritmo cuando las propiedades del sistema se alejan de las condiciones ideales.

El método SOR mostró un comportamiento intermedio. Aunque logró converger en los escenarios ideal y de estrés, no consiguió alcanzar la convergencia en el escenario mal condicionado, evidenciando que la utilización del factor de relajación no siempre garantiza mejoras cuando la matriz presenta una estructura numéricamente inestable.

VALIDACIÓN DE LA PROPUESTA COMPUTACIONAL

Los resultados obtenidos permiten validar el modelo matemático y la implementación desarrollada. La aplicación fue capaz de generar automáticamente sistemas lineales asociados a diferentes condiciones clínicas, resolverlos mediante múltiples métodos numéricos y comparar objetivamente su desempeño.

La consistencia de las soluciones obtenidas en los escenarios estables y el comportamiento esperado de los algoritmos frente al mal condicionamiento confirman la correcta implementación de los procedimientos matemáticos y computacionales utilizados en el proyecto.



APLICACIÓN WEB DESARROLLADA

ARQUITECTURA GENERAL DEL SISTEMA

La solución fue desarrollada utilizando el framework Flask bajo una arquitectura cliente-servidor. La aplicación recibe los parámetros fisiológicos ingresados por el usuario, construye automáticamente el sistema lineal correspondiente y ejecuta los métodos numéricos implementados para obtener la solución.

El flujo general de funcionamiento es:

Usuario → Formulario Web → Construcción del Sistema → Métodos Numéricos → Resultados → Visualización

MÓDULO DE CONSTRUCCIÓN DEL SISTEMA

Este módulo transforma los parámetros fisiológicos del paciente en una matriz de coeficientes A y un vector de términos independientes b.

Las variables consideradas son:

- Edad del paciente.
- Peso corporal.
- Severidad sintomatológica.
- Nivel de actividad física.

A partir de estos parámetros se generan automáticamente los escenarios:

- Escenario Ideal.
- Escenario de Estrés.
- Escenario Mal Condicionado.

Esto permite analizar el comportamiento de los algoritmos bajo diferentes condiciones numéricas.

IMPLEMENTACIÓN DE LOS MÉTODOS NUMÉRICOS

La aplicación incorpora cinco métodos para resolver el sistema lineal:

Método	Tipo
Factorización LU	Directo
Jacobi	Iterativo
Gauss-Seidel	Iterativo
SOR	Iterativo
Gradiente Conjugado Precondicionado	Iterativo

Para cada algoritmo se registra:

- Solución obtenida.
- Número de iteraciones.
- Estado de convergencia.
- Historial de errores.

Esta información permite realizar comparaciones objetivas entre los distintos métodos.


VISUALIZACIÓN Y ANÁLISIS DE RESULTADOS


La interfaz muestra automáticamente:

- Matriz de coeficientes A.
- Vector independiente b.
- Número de condición.
- Clasificación del sistema.
- Solución mediante Factorización LU.
- Comparación de convergencia entre métodos.
- Historial iterativo.
- Representación geométrica 3D del sistema reducido 3×3.

La incorporación de visualizaciones facilita la interpretación de los resultados y mejora el análisis del comportamiento numérico de cada escenario.

CAPTURAS DE LA APLICACIÓN





Las capturas presentadas a continuación corresponden al escenario ideal del sistema, utilizando los valores predeterminados del caso de estudio (edad = 50 años, peso = 70 kg, severidad = 5 y nivel de actividad física = 5). Este escenario representa una condición numéricamente estable y bien condicionada, permitiendo observar el funcionamiento completo de la aplicación, la construcción automática del sistema lineal, la ejecución de los métodos numéricos implementados y la visualización de los resultados obtenidos. Las imágenes evidencian la correcta integración de los componentes matemáticos y computacionales desarrollados durante el proyecto.

CONCLUSIONES

El desarrollo de la aplicación permitió implementar y comparar distintos métodos numéricos para la resolución de sistemas de ecuaciones lineales asociados a un modelo clínico-computacional. Los resultados obtenidos demostraron que las propiedades matemáticas de la matriz, especialmente su condicionamiento y predominancia diagonal, influyen directamente en la velocidad de convergencia y estabilidad de los algoritmos. La Factorización LU se consolidó como el método más robusto al proporcionar soluciones en todos los escenarios analizados, mientras que el Gradiente Conjugado Precondicionado presentó el mejor desempeño iterativo en los sistemas bien condicionados.

Asimismo, el proyecto permitió comprobar experimentalmente conceptos fundamentales de Álgebra Lineal y Métodos Numéricos mediante una aplicación web interactiva que integra modelado matemático, análisis computacional y visualización de resultados. La comparación entre los escenarios ideal, de estrés y mal condicionado permitió evidenciar cómo el deterioro progresivo del condicionamiento de la matriz afecta directamente el comportamiento de los métodos iterativos, incrementando el número de iteraciones requeridas para alcanzar la convergencia e incluso impidiendo la convergencia en algunos casos. Los resultados obtenidos se resumen en la siguiente tabla comparativa:

Método	Iteraciones (Ideal)	Iteraciones (Estrés)	Iteraciones (Mal Condicionado)	Convergencia
Jacobi	9	38	250	No en caso mal condicionado
Gauss-Seidel	6	10	5	Sí
SOR ($\omega = 1.3$)	16	18	250	No en caso mal condicionado
Gradiente Conjugado Precondicionado	5	5	250	No en caso mal condicionado
Factorización LU	1	1	1	Sí